Benchmark y evaluación del sistema de recuperación

Proyecto 1 de PLN · Recuperación de opiniones de Steam (etapa 1) · Sección 9 de la práctica

23 de octubre de 2026

1. Resumen

Este documento describe únicamente la construcción del benchmark y la evaluación cuantitativa del sistema (VSM con similitud coseno sobre 600 reseñas de seis juegos de Steam). Se completaron las piezas que faltaban: los juicios de relevancia, el ranking oficial de las 15 consultas y el cálculo de métricas, más una comparación de las 12 configuraciones de representación.

- **queries.tsv**: 15 consultas (5 fáciles, 5 medias, 5 difíciles). Se reemplazó Q04 porque el corpus no la podía sustentar (ver 2).
- **qrels.tsv**: 222 pares consulta–documento relevantes (120 con relevancia 2 y 102 con relevancia 1), entre 12 y 15 por consulta.
- **candidatos_qrels.tsv**: los 30 candidatos por consulta, ahora con la columna `relevance` llena (0, 1 o 2).
- **rankings.tsv**: Top-10 de las 15 consultas (150 filas) con la configuración `review / tfidf / unigram`.
- **Resultado**: P@10 = 0.327, R@10 = 0.223, F1@10 = 0.265, MRR = 0.619 y nDCG@10 = 0.311. TF-IDF con unigramas es la mejor representación de las 12 probadas.

2. Consultas del benchmark

Las consultas cubren aspectos que aparecen en las reseñas de los seis juegos (Counter-Strike 2, Dota 2, Portal 2, Stardew Valley, Baldur's Gate 3 y Guilty Gear -Strive-). La última columna muestra la consulta después de aplicarle la misma normalización que al corpus (tokenización, eliminación de artículos, preposiciones, conjunciones y pronombres por POS, y lematización).

ID	Nivel	Consulta	Consulta normalizada
Q01	Fácil	cheaters in competitive matches	`cheater competitive match`
Q02	Fácil	game crashes and freezes	`game crash freeze`
Q03	Fácil	great story and characters	`great story character`
Q04	Fácil	the game is too hard	`game be too hard`
Q05	Fácil	poor server connection	`poor server connection`
Q06	Media	the game runs badly on my computer	`game run badly computer`
Q07	Media	playing with friends makes the experience better	`play friend make experience well`
Q08	Media	too many paid items and microtransactions	`too many pay item microtransactions`
Q09	Media	the controls are frustrating to learn	`control be frustrate learn`
Q10	Media	repetitive activities after many hours	`repetitive activity many hour`
Q11	Difícil	unfair opponents ruin online matches	`unfair opponent ruin online match`
Q12	Difícil	technical problems interrupt the experience	`technical problem interrupt experience`
Q13	Difícil	the world rewards curiosity and exploration	`world reward curiosity exploration`
Q14	Difícil	the game demands a lot of practice to improve	`game demand lot practice improve`
Q15	Difícil	the experience becomes boring over time	`experience become bore over time`

Cambio en Q04. La consulta original era *“difficult boss fights”*. Al revisar el corpus completo, solo 2 de las 600 reseñas contienen la palabra *boss* y ninguna habla de verdad de combates contra jefes, de modo que era imposible reunir los 10–15 documentos relevantes que exige la práctica. Se sustituyó por *“the game is too hard”*, que conserva el tema (dificultad), mantiene el nivel fácil (fuerte coincidencia léxica con *hard*/*too hard*) y tiene 24 reseñas relevantes en el corpus. El resto de las consultas no cambió.

3. Juicios de relevancia (qrels.tsv)

Escala utilizada

Valor	Significado	Criterio aplicado
2	Muy relevante	La reseña trata el aspecto de la consulta tal como está planteado, de forma clara y central.
1	Parcialmente relevante	Trata el aspecto de forma breve, indirecta o parcial, o lo menciona con la polaridad contraria (p. ej. “nunca se vuelve aburrido” para Q15, “no hay cheaters” para Q01).
0	No relevante	No trata el aspecto, aunque comparta palabras con la consulta (p. ej. “poor” en “I'm too poor for characters” para Q05).

Procedimiento

- **Lectura completa del corpus.** Se leyeron las 600 reseñas (texto original, no el normalizado) y se evaluó cada una contra las 15 consultas por su significado, sin mirar puntuaciones del modelo. Así los juicios no dependen de lo que el VSM logre recuperar, que es justo lo que se quiere medir.
- **Control cruzado por pooling.** Se juntaron los Top-10 con puntuación mayor a 0 de las 12 configuraciones y se revisaron a mano los documentos del pool marcados como 0. Esa revisión agregó 12 relevantes parciales (casi todos de polaridad contraria) y no cambió ningún documento de qrels.tsv.

- **Límite de 10–15 relevantes.** En 14 consultas el corpus tiene más de 15 reseñas relevantes. Se conservaron primero las de valor 2 y después las de valor 1 más claras, siempre con ambos valores presentes, como pide la práctica. Todos los juicios positivos, incluidos los que no entraron, quedaron en **juicios_relevancia_completos.tsv** (columna en_qrels).
- **Validación de formato.** Sin pares duplicados, todos los document_id existen en el corpus, solo valores 1 y 2, y cada consulta tiene entre 10 y 15 relevantes con ambos valores. El comando evaluate lo verifica sin errores.

Consulta	En qrels	Valor 2	Valor 1	Relevantes encontrados en el corpus
Q01	15	11	4	26
Q02	12	5	7	13
Q03	15	10	5	60
Q04	15	7	8	24
Q05	15	7	8	16
Q06	15	2	13	19
Q07	15	13	2	34
Q08	15	10	5	24
Q09	15	5	10	21
Q10	15	2	13	19
Q11	15	10	5	25
Q12	15	13	2	23
Q13	15	10	5	24
Q14	15	12	3	29
Q15	15	3	12	23
Total	**222**	**120**	**102**	**380**

Q02 tiene 12 relevantes porque solo 13 reseñas del corpus tratan, total o parcialmente, cierres, congelamientos o fallos que detienen el juego; las demás consultas se completaron al máximo de 15.

4. Ranking oficial (rankings.tsv)

Se ejecutó `python recuperacion.py rank` con la configuración por defecto del proyecto: contenido `review`, representación `tfidf` y `unigram`. El archivo tiene 150 filas (10 por consulta) con `query_id`, `document_id`, `rank` y `score`, en el formato de la práctica. Junto a él se regeneró `rankings_metadata.json` con la huella del corpus y de las consultas. Para las 14 consultas que no cambiaron, el ranking es idéntico al que ya existía.

5. Resultados de la configuración oficial

Las métricas son las de la práctica: Precision@10, Recall@10, F1@10, RR (cuyo promedio es el MRR) y nDCG@10 con ganancia $2^{rel}-1$. Los valores 1 y 2 cuentan como relevantes para P, R, F1 y RR; nDCG usa además el grado.

Consulta	Nivel	P@10	R@10	F1@10	RR	nDCG@10
Q01	Fácil	0.500	0.333	0.400	0.500	0.410
Q02	Fácil	0.500	0.417	0.455	1.000	0.662
Q03	Fácil	0.100	0.067	0.080	0.125	0.069
Q04	Fácil	0.600	0.400	0.480	1.000	0.575
Q05	Fácil	0.500	0.333	0.400	0.333	0.312
Q06	Media	0.500	0.333	0.400	1.000	0.447
Q07	Media	0.500	0.333	0.400	1.000	0.633
Q08	Media	0.400	0.267	0.320	0.200	0.292
Q09	Media	0.300	0.200	0.240	1.000	0.406
Q10	Media	0.000	0.000	0.000	0.000	0.000
Q11	Difícil	0.300	0.200	0.240	1.000	0.178
Q12	Difícil	0.100	0.067	0.080	0.125	0.069
Q13	Difícil	0.200	0.133	0.160	0.500	0.208
Q14	Difícil	0.200	0.133	0.160	1.000	0.293
Q15	Difícil	0.200	0.133	0.160	0.500	0.112
Promedio	**15**	**0.327**	**0.223**	**0.265**	**0.619**	**0.311**

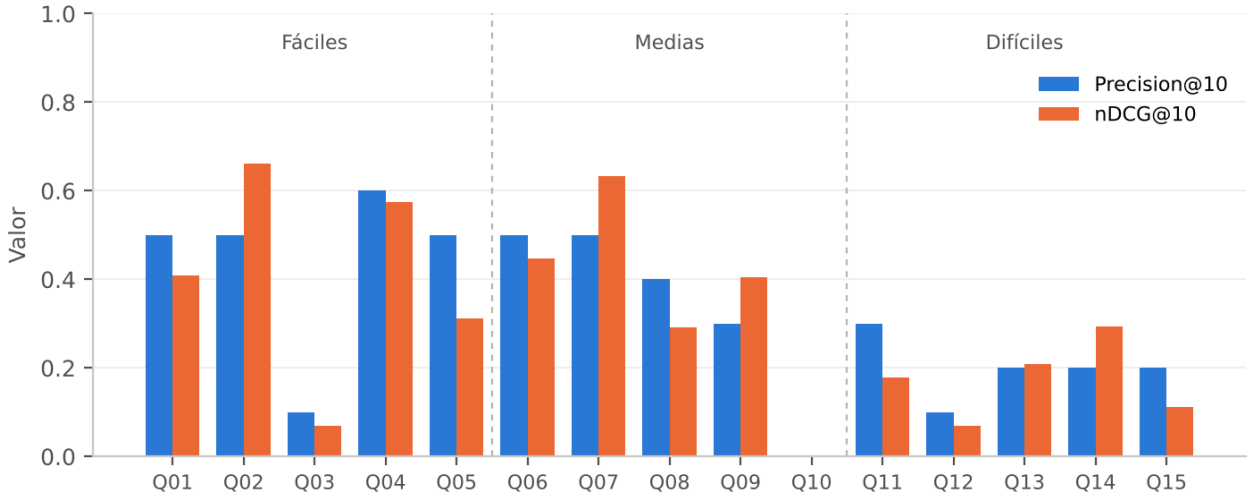


Figura 1. Precision@10 y nDCG@10 por consulta (review · tfidf · unigram). Q10 no recupera ningún relevante.

Promedios por nivel de dificultad

Nivel	P@10	R@10	F1@10	MRR	nDCG@10
Fácil (5)	0.440	0.310	0.363	0.592	0.405
Media (5)	0.340	0.227	0.272	0.640	0.355
Difícil (5)	0.200	0.133	0.160	0.625	0.172

El desempeño cae con la dificultad, como se esperaba: la precisión baja de 0.44 en las consultas fáciles a 0.20 en las difíciles, y el nDCG@10 pasa de 0.41 a 0.17. Las consultas difíciles describen el aspecto con palabras que las reseñas casi no usan, y el VSM solo puede premiar coincidencias exactas de términos. El MRR se mantiene alto en los tres niveles (0.59–0.64): casi siempre aparece algún relevante cerca del primer lugar, pero el resto del Top-10 se llena de reseñas que

comparten palabras genéricas.

Nota sobre el límite de 15. Si el Top-10 se califica con todos los juicios positivos encontrados (no solo con los de qrels.tsv), la P@10 de esta configuración sube de 0.327 a 0.440. La diferencia viene sobre todo de Q03, donde hay 60 reseñas que elogian la historia o los personajes pero solo caben 15 en qrels. Las métricas oficiales son las de qrels.tsv; este dato solo sirve para interpretarlas.

6. Comparación de las 12 configuraciones

Se agregó a `recuperacion.py` el comando `benchmark`, que ejecuta las 15 consultas con cada combinación de contenido (review o item_review), representación (frecuencia, binaria o TF-IDF) y n-gramas (unigramas o bigramas) y las evalúa contra el mismo qrels.tsv. No modifica rankings.tsv: guarda los 12 rankings y las tablas en la carpeta `benchmark/`.

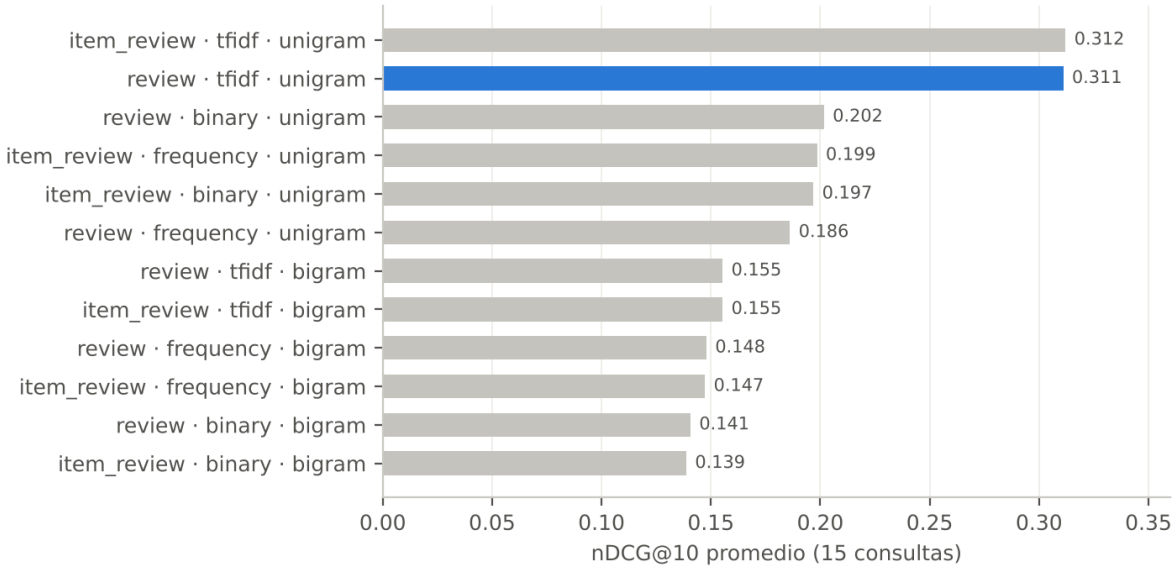


Figura 2. nDCG@10 promedio por configuración. En azul, la configuración usada en rankings.tsv.

Configuración	P@10	R@10	F1@10	MRR	nDCG@10	Consultas sin términos
item_review · tfidf · unigram	0.327	0.223	0.265	0.619	0.312	0
review · tfidf · unigram	0.327	0.223	0.265	0.619	0.311	0
review · binary · unigram	0.200	0.134	0.161	0.528	0.202	0
item_review · frequency · unigram	0.207	0.140	0.167	0.568	0.199	0
item_review · binary · unigram	0.193	0.130	0.155	0.524	0.197	0
review · frequency · unigram	0.193	0.131	0.156	0.528	0.186	0
item_review · tfidf · bigram	0.133	0.090	0.107	0.316	0.155	7
review · tfidf · bigram	0.133	0.090	0.107	0.316	0.155	7
review · frequency · bigram	0.133	0.090	0.107	0.316	0.148	7
item_review · frequency · bigram	0.127	0.086	0.102	0.316	0.147	7
review · binary · bigram	0.127	0.086	0.102	0.316	0.141	7
item_review · binary · bigram	0.127	0.086	0.102	0.316	0.139	7

- **TF-IDF es claramente superior.** Con unigramas alcanza nDCG@10 ≈ 0.31, contra ≈ 0.19–0.20 de frecuencia y binaria. Al bajar el peso de términos muy frecuentes en el corpus

(*game*, *be*, *play*), el ranking depende de las palabras que distinguen el aspecto buscado.

- **Los bigramas rinden peor en todas las representaciones.** 7 de las 15 consultas normalizadas no comparten ningún bigrama con el vocabulario, así que todas sus puntuaciones son 0 y el orden resultante es arbitrario: el sistema devuelve los primeros documentos del corpus. Los aciertos que aparecen en esos casos son casualidad, no evidencia de buen desempeño.
- **Agregar el nombre del juego (item_review) casi no cambia nada** (0.312 contra 0.311 en TF-IDF unigramas): las consultas no mencionan juegos, así que esos términos rara vez coinciden. Por eso se dejó la configuración por defecto, review · tfidf · unigram.

7. Observaciones para el análisis de errores

La práctica pide el análisis de errores en otra sección (12). Aquí solo se dejan señalados los casos que el benchmark hace evidentes, como punto de partida:

- **Mejor desempeño** (nDCG@10 más alto): Q02 *game crashes and freezes*, Q07 *playing with friends...*, Q04 *the game is too hard*, Q06 *the game runs badly...* y Q01 *cheaters...*. Tienen términos específicos y poco ambiguos (*crash*, *friend*, *hard*, *cheater*).
- **Peor desempeño**: Q10 *repetitive activities after many hours* (0 relevantes: *many hour* atrae reseñas que solo presumen horas jugadas), Q03 y Q12 (los adjetivos genéricos *great* y *experience* dominan sobre *story*/*character* y *technical*), Q15 y Q11 (sinónimos y paráfrasis: *boring* frente a *burnt out*; *unfair opponents* frente a *smurfs*, *boosters* o *hackers*).
- **Polisemia**: en Q05, *poor* recupera "the character design is poor" y "too poor for characters". **Lematización**: *better* se normaliza como *well* en Q07.

8. Cambios en el código y cómo reproducirlo

- **Huella independiente del sistema operativo.** `corpus_fingerprint` ahora fija el salto de línea en \n y el hash de queries.tsv ignora \r\n. Antes, la huella calculada en Windows no coincidía con la de Linux o macOS, y `evaluate` podía fallar con "El corpus difiere..." aunque nada hubiera cambiado. Esta corrección cambia la huella guardada, por lo que se volvieron a generar los 12 modelos con `build`.
- **Comando nuevo** `benchmark` y función `compute_metrics`: las métricas se calculan con el mismo código que usa `evaluate`, cuyo comportamiento no cambió.

Secuencia completa, desde la carpeta raíz del proyecto:

```
python recuperacion.py build
python recuperacion.py rank
python recuperacion.py evaluate
python recuperacion.py benchmark
```

Archivos del benchmark

Archivo	Contenido
queries.tsv	15 consultas congeladas (query_id, difficulty_level, query).
qrels.tsv	222 juicios relevantes (query_id, document_id, relevance) con valores 1 y 2.
juicios_relevancia_completos.tsv	Los 380 juicios positivos encontrados, con juego, texto y si entraron a qrels.
candidatos_qrels.tsv	30 candidatos por consulta con la columna relevance calificada.
rankings.tsv / rankings_metadata.json	Top-10 oficial (review · tfidf · unigram) y su huella.
evaluacion_por_consulta.tsv / evaluacion_promedios.tsv	Salida de evaluate.
benchmark/	12 rankings, comparativa_configuraciones.tsv y metricas_por_consulta_y_configuracion.tsv.

9. Limitaciones

- Los juicios los asignó un solo evaluador. Lo recomendable es que otro integrante del equipo revise una muestra (por ejemplo, 3 consultas) y que se discutan los desacuerdos antes de entregar.
- El tope de 15 relevantes por consulta subestima la precisión en consultas con muchos relevantes (Q03, Q07 y Q14) y hace que el Recall@10 máximo posible sea 10/15 ≈ 0.67.
- El benchmark debe considerarse congelado: si cambian el corpus, la normalización o las consultas, hay que revisar qrels.tsv y volver a generar los rankings.